



TALOS 宣言

AI 时代的个人上下文主权

Trusted AI Life Operating System White Paper v0.4

不把模型训练成你，而是给任何 AI
一套稳定读取"你是谁、你要什么、如何与你协作"的上下文协议。

作者：外脑玩家 版本：v0.4（实战更新版） 日期：2026-06-04

目录

Contents

0. 在你读下去之前

1. 执行摘要

2. TALOS 定义

3. 正面交锋：TALOS vs 三个假想敌

4. 实战证据：外脑玩家「超级大脑」

5. 理论基础（浓缩版）

6. 产业趋势定位：TALOS 填的是哪个空

7. TALOS 八层架构

8. TALOS 运行机制

9. Context 健康模型：散、脏、腐

10. TALOS 成熟度模型（含自测）

11. 最小可行 TALOS：30 分钟启动

12. 风险与治理

13. TALOS 设计原则

14. 应用场景

15. 从个人到产品：TALOS 的商业化路径

16. 未来判断

17. 结论

18. 参考文献与外部来源

3

3

4

4

5

7

7

8

9

10

10

11

11

12

12

12

13

13

13

0. 在你读下去之前 Before You Read

昨天你让 ChatGPT 帮你写一篇文章。你花了 10 分钟解释你的风格偏好，5 分钟说明你的目标受众，3 分钟纠正它用了你讨厌的词。终于输出像样了。

今天你打开一个新对话 一切归零。

这不是你的问题，也不是模型的问题。这是上下文真空的问题。

你每天花多少时间给 AI 解释你是谁？

1. 执行摘要 Executive Summary

AI 正在从「一次性问答工具」进入「长期协作智能体」阶段。模型越来越强，但你的上下文依然破碎。

每次对话，你都在重复：我是谁、我在做什么、我喜欢什么风格、我的项目在哪、哪些事情不能做、哪些经验已经被验证过。没有稳定上下文，AI 就是每天重置记忆的实习生；有稳定上下文，AI 才是长期搭档。

本文提出 TALOS 个人上下文操作系统（Trusted AI Life Operating System，简称 TALOS）：一种面向智能体时代的个人知识基础设施。它把你的身份、目标、偏好、经验、审美、项目、 workflow、样本和权限边界，整理成人类可读、AI 可读、可检索、可迁移、可维护的上下文资产。

核心判断

不把模型训练成你，而是给任何 AI 一套稳定读取“你是谁、你要什么、如何与你协作”的上下文协议。

未来个人与 AI 的协作质量，不只取决于模型能力，更取决于个人是否拥有高质量、可读取、可更新、可迁移的上下文资产。

本文基于三类证据

科研证据：MemGPT、GenerativeAgents、Mem0、Zep、SecondMe、PersonaKnowledgeGraph、RAG、Agent Memory 等研究一致指向 长期记忆、动态检索、知识图谱和上下文管理是 Agent 的核心基础设施。

产业趋势：ChatGPT Memory、MCP、Letta、Zep、AWS AgentCore Memory 等产品都在构建「记忆层 / 上下文层 / 工具连接层」 基础设施有了，记忆层产品有了，缺的是个人层面的上下文主权。

实战证据：外脑玩家的 Obsidian + Claude Code「超级大脑」系统，Vault 已持续演化 15 个月，其中 TALOS 形态稳定运行 6 个月+，形成 Identity 三文件、分形目录、frontmatter 契约、工作流命令、

记忆候选池、熵减维护机制 TALOS 不是理论，是已跑通的原型。

2. TALOS 定义 Definition

TALOS 是一套由个人主动构建和维护的身份、目标、偏好、经验、审美、项目、样本、工作流、权限边界与知识资产系统。以开放格式存在，可被不同 AI 模型、智能体和自动化工具读取、检索、调用和更新，从而支持稳定的长期个人化协作。

一句话版本：TALOS 是 AI 时代的"个人说明书 + 经验库 + 审美样本 + 项目地图 + 工作流协议 + 权限系统"。

为什么叫 TALOS

三千年前的克里特岛，赫菲斯托斯锻造了一个青铜守卫 Talos。全身刀枪不入，灵液（ichor）驱动运转，每天绕岛三圈巡逻，守护米诺斯文明的边界。唯一弱点在脚踝：一颗铆钉封住灵液的出口。TALOS 继承了青铜守卫的名字，也继承了它的设计哲学：

- 锻造 知识库是工程产物，不是囤积物
- 灵液 结构化 Context 是系统的命脉
- 巡逻 自动化运维，24/7 不间断
- 守护 个人上下文主权，不被平台锁死
- 命门 最终判断力在人，不在系统

它解决的问题

没有 TALOS	有 TALOS
每次对话重复解释身份	AI 读取 Identity 层，30 秒进入状态
输出风格每次漂移	读取偏好与样本，风格稳定
项目上下文每次丢失	读取项目层，延续上次进度
踩过的坑重复踩	读取经验库，已验证的判断自动复用
Agent 跑着跑着失控	维护与压缩机制保证上下文新鲜
平台记忆被锁定	本地优先、开放格式、跨模型可迁移

3. 正面交锋：TALOS vs 三个假想敌 Positioning

3.1 vs ChatGPT Memory（平台记忆）

维度	ChatGPT Memory	TALOS
谁拥有数据	OpenAI	你自己
能否导出迁移	不完整，格式不透明	Markdown / YAML，随便搬
结构透明度	黑箱	完全可读可审计
隐私粒度	粗（开 / 关）	细（公开 / 协作 / 私密 / 禁止）
跨平台可用性	只在 ChatGPT 内	任何模型、任何工具

一句话：ChatGPT Memory 是租的公寓，TALOS 是你自己的房子。平台记忆方便，但方便不等于主权。你的核心上下文放在别人服务器上，规则别人定、格式别人改、哪天收费别人说了算。

3.2 vs RAG 文档库

维度	RAG 文档库	TALOS
存什么	文档、资料	身份 + 偏好 + 审美 + 权限 + 工作流 + 文档
AI 读到什么	检索关键词匹配的段落	理解你是谁、你怎么做事、你要什么结果
有人格吗	没有	有 Identity 层
能执行吗	不能，只检索	能 工作流层 + 权限层
能进化吗	需人工维护	候选池 + 回流机制自动进化

一句话：RAG 是搜索引擎，TALOS 是懂你的搭档。普通 RAG 解决"找到信息"，TALOS 解决"AI 理解你"。

3.3 vs 微调 / 数字分身

维度	微调 / 数字分身	TALOS
改什么	模型参数	上下文供给
可解释吗	黑箱	完全透明
演化方式	每次微调都要重新训练	每次协作都在自动沉淀
成本	高（GPU + 数据）	低（Markdown + 结构化）
目标	让 AI 像你	让 AI 懂你、按你的系统工作

TALOS 的目标不是让 AI"像我"，而是让 AI"懂我，并按我的系统工作"。

4. 实战证据：外脑玩家「超级大脑」Proof

不废话，先看数据。

16

个月+ Vault 演化

1300+

篇笔记资产

10

个工作流命令

4.1 系统概览

指标	数据
运行时长	16 个月+ (Vault 演化) ，其中 TALOS 形态 7 个月+
笔记总量	1300+ 篇 (含主动熵减归档，净增质量而非数量)
目录层级	4 层分形 (L0 治理自检 L1 全局规则 L2 目录地图 L3 笔记契约)
工作流命令	10 个 (intake / digest / maintain / retrieval / memory / create / morning / mine-rules / full-cycle / weekly-reset)
身份文件	4 个 (TELOS / CONTEXT / PROFILE / voice-profile)
AI 协作频率	每日

4.2 Before vs After (让 AI 写一篇方法论文章)

Before (没有 TALOS)	After (有 TALOS)
打开 ChatGPT 反复解释身份、风格、用语、结构	打开 Claude Code 自动读取 TELOS + CONTEXT + PROFILE
来回 5 轮 40 分钟 输出勉强能用	30 秒进入状态 10 分钟出初稿，风格对路
下次又要重来	经验自动回流到知识库

差距不是 4 倍效率。差距是"每次从零开始" vs "每次站在自己肩膀上"。

4.3 关键设计

Identity 三文件 TALOS 的人格内核：

- Identity/TELOS.md 我是谁、我要什么、我信什么 (目标层 + 身份层)
- Identity/CONTEXT.md 我现在在做什么 (项目层)
- Identity/PROFILE.md 我喜欢什么、讨厌什么、怎么沟通 (偏好层 + 边界层)
- Identity/voice-profile.md 可移植声音档案 (用于外部 AI 工具)

分形目录 每一层都能独立被 AI 理解：

L0 validate-governance.sh治理自检（结构 / 命令 / 项目三类漂移检测）
L1 CLAUDE.md全局规则（系统怎么运转）
L2 _README.md每个目录的地图
L3 frontmatter每篇笔记的契约

记忆候选池 AI 观察到的偏好不直接写入，先暂存再审批：AI 观察到偏好 写入 candidates.md
用户确认 晋升正式 PROFILE。这不是理论假设，是每天在跑的机制。

自成长回路 observe.py（观察器） patterns.json（模式识别） candidates.md（候选池）
/digest（人工确认） PROFILE / OPERATING_RULES。系统会从日常协作中自动发现偏好模式，等你确认后生效 不会偷偷改你，也不会错过你真正想要的东西。

5. 理论基础（浓缩版） Foundations

理论	核心主张	TALOS 取了什么
扩展心智（Clark & Chalmers）	认知不只发生在脑内，笔记 / 工具 / 环境也是认知的一部分	TALOS 是个人与 AI 之间的扩展认知接口
个人知识管理	知识需收集、整理、关联、复用	加一条：知识还要能被 AI 正确调用
RAG（Lewis et al.）	模型回答前先检索外部知识	无需训练，结构化 + 按需检索即可
Agent Memory（MemGPT / Mem0 / Zep）	智能体需要可管理的长期记忆架构	对应记忆候选池、熵减维护、压缩机制
个人知识图谱（Balog & Kenter）	关系比信息量更重要	分形目录 + wikilink + frontmatter 构成轻量知识图谱

从哲学到工程到产品，所有方向都在指向同一个结论 个人需要一套结构化的、AI 可读的上下文系统。

6. 产业趋势定位：TALOS 填的是哪个空 Industry Map

时间	事件
2024	MCP 发布 AI-工具连接的标准化接口出现
2024	ChatGPT Memory 平台开始做个人记忆
2025	Mem0 / Zep / Letta 记忆层产品爆发（面向开发者）
2025	AWS AgentCore Memory 云厂商入场，记忆成基础设施
2025	Second Me 个人 AI 主权概念浮出水面

时间	事件
2026	MCP 生态爆发 / Claude Code 企业化 个人 Agent 基础设施成刚需
2026	TALOS 个人上下文主权（TALOS 在这里）

MCP 解决了"AI 怎么连工具" TALOS 解决"AI 怎么连你"

Mem0 / Zep 解决了"Agent 怎么记东西" TALOS 解决"记的东西归谁、怎么更新、怎么迁移"

ChatGPT Memory 解决了"平台帮你记" TALOS 解决"你自己记，带到任何平台"

产业正在从"谁的模型更强"转向"谁的上下文更好"。个人层面，这个"谁"就是你。

7. TALOS 八层架构 Architecture

从「我是谁」到「能 / 不能做什么」，八层逐级供给 AI 读取与推理。

层	名称	English	回答的问题
01	身份层	Identity	我是谁
02	目标层	Telos	我要去哪
03	偏好层	Preference	我喜欢什么
04	经验层	Experience	我验证过什么
05	项目层	Project	我正在做什么
06	样本层	Taste Samples	什么符合品味
07	工作流层	Workflow	如何做事
08	边界层	Permission	能 / 不能做什么

7.1 身份层 Identity：我是谁

- 普通人进入 AI 领域的关键节点
- AI 工具领域内容创作者
- 系统搭建者
- 外挂大脑方法论布道者

7.2 目标层 Telos：我要去哪

- 成为 AI 工具领域 KOL
- 建立稳定一人企业
- 打造年轻人可复制的 0-1 方法论
- 当前聚焦内容引擎 + 陪跑服务 MVP

7.3 偏好层 Preference：我喜欢什么

- 称呼"外脑玩家Haaper"
- 800 字内，简洁精准
- 极简、原子化笔记
- 禁止 AI 味口头禅、禁止互联网黑话

7.4 经验层 Experience：我验证过什么

- Context资产论：AI系统的真正护城河
- Claude Code 协作心法：6 个 Context 管理原则
- AI 落地三原则：分层评估 Aha 优先 产出回流
- 做事用系统不要状态

7.5 项目层 Project：我正在做什么

- TALOS 品牌发布（P0）
- 内容引擎（P0）
- 陪跑服务 MVP（P0）
- B 端系统架构服务（医美 / 科研 / 医疗）
- GEO 个人站点
- 钩子产品 / 私域社群（待启动）

7.6 样本层 Taste Samples：什么符合我的品味

样本层是 TALOS 的高阶资产。审美很难被抽象描述，但可以通过样本让 AI 学习 好文章 / 标题 / 封面 / 产品 / 文案样本，以及反面样本（"不要写成这样"比"写成这样"更有信息量）。

7.7 工作流层 Workflow：我如何做事

工作流层让 AI 从「回答者」变成「协作者」。外脑玩家系统已有 10 个命令：/intake、/digest、/maintain、/retrieval、/memory、/create、/morning、/mine-rules、/full-cycle、/weekly-reset。

7.8 边界层 Permission：能做什么，不能做什么

可自动执行	必须确认	禁止执行
整理、检索、生成草稿、提出建议	修改 Identity、发布内容、删除文件、付款、对外发送	泄露隐私、篡改核心信念、绕过审核、破坏文件结构

8. TALOS 运行机制 Mechanism

输入 结构化 索引 调用 执行 反馈 沉淀。TALOS 是循环，不是静态资料夹。

机制	做什么	为什么重要
写入	信息进入时标注来源、类型、状态、用途	否则知识库变数字囤积
检索	AI 按任务读取相关上下文，不一次全读	上下文窗口是稀缺资源
压缩	周期性摘要、合并、去重、归档	长期系统必然膨胀
审核	关键偏好、身份、事实必须经用户确认	AI 自动写入可能错误或片面
回流	每次协作产出「任务结果 + 经验沉淀」	与 AI 落地三原则一致

9. Context 健康模型：散、脏、腐 Context Health

病理	表现	后果	治理
散	信息分散在多个地方	AI 找不到关键背景	统一入口、目录索引、链接
脏	格式混乱、无元数据、噪音多	AI 读不准	Markdown + frontmatter + 清洗
腐	信息过时、矛盾、冗余	AI 基于旧上下文行动	/maintain、摘要、归档、版本控制

堆信息是本能，减噪音是能力。TALOS 的长期价值不来自「有多少内容」，而来自熵减能力。

10. TALOS 成熟度模型（含自测） Maturity

等级	名称	状态	自测：你的 AI 能做到吗？
L0	临时 Prompt	无系统	每次对话都要从零解释背景？
L1	个人资料卡	有身份	能不问你就准确描述你的职业和核心目标？
L2	AI 可读知识库	有结构	能自动检索笔记，找到与当前任务相关的历史内容？
L3	工作流系统	能执行	能自动执行完整工作流，不需逐步指令？
L4	记忆系统	能进化	能从协作中沉淀偏好和经验，下次自动应用？
L5	个人智能体 OS	能协作	能在你睡觉时完成任务，早上给你可审阅结果？
L6	可产品化 TALOS	能交付	能把这套系统复制给别人并跑起来？

外脑玩家当前：L4 L5 之间，产品化方案正在迈向 L6。大多数人停在 L0；到 L3 就已经能感受到质的差异 AI 从「每次重新认识你」变成「像共事半年的搭档」。

11. 最小可行 TALOS：30 分钟启动 Starter Kit

一个普通人不需要一开始就搭复杂系统。9 个文件即可起步：

Identity/	Methods/
00-我是谁.md	我的方法论.md
01-长期目标.md	Samples/
02-当前状态.md	我认可的样本.md
03-偏好与禁区.md	AI-Rules/
Projects/	AI协作说明.md
项目总览.md	权限边界.md

30 分钟启动法

时间	动作	产出
5 分钟	写一句身份	我是谁
5 分钟	写三个目标	我要什么
5 分钟	写五条偏好	我喜欢什么
5 分钟	写三个项目	我在做什么
5 分钟	写三个禁区	AI 不能做什么
5 分钟	给 AI 读取并测试	AI 能否正确介绍你？

最后一个 5 分钟是关键 测试你的 AI 是否能读完这些文件后，在不问你任何问题的情况下准确描述你是谁。如果它能，你的 TALOS 就已经工作了。

12. 风险与治理 Risk & Governance

12.1 隐私分级

- 公开上下文：可给任何 AI 读取（职业、公开目标、写作风格）
- 协作上下文：可给工作 AI 读取（项目详情、方法论、客户信息）
- 私密上下文：仅本地保存，谨慎读取（个人财务、家庭信息）
- 禁止上下文：AI 默认不得访问（密码、密钥、法律敏感信息）

12.2 12.5 其它治理要点

记忆污染：AI 自动写入可能错误片面，采用候选池机制 观察 候选池 确认 晋升。

平台锁定：核心上下文保存在 Markdown / YAML / JSON 等开放格式。你可被任何平台服务，但不可被任何平台拥有。

权限失控：AI 同时握有私密数据、外部通信与执行权限时风险陡增，必须写清权限边界。

Context Rot：上下文越长不等于越好。需定期维护，而非无限堆叠 这正是 /maintain 的意义。

13. TALOS 设计原则 Design Principles

#	原则	含义
1	本地优先	核心上下文由用户拥有
2	开放格式	Markdown、YAML、JSON
3	人机共读	人能看懂，AI 能解析
4	少而准	宁少勿脏
5	样本驱动	审美和风格靠样本，不靠空话
6	工作流优先	能执行的知识才是真资产
7	权限分级	越接近发布 / 金钱 / 删除 / 隐私，越需确认
8	持续熵减	定期清理、压缩、归档
9	经验回流	每次协作都沉淀可复用经验
10	跨模型可迁移	不锁死在单个平台

14. 应用场景 Use Cases

内容创作者：读取选题池、表达风格、爆款样本、平台规则 辅助选题、写稿、改稿、多平台拆分。

顾问 / 教练：读取方法论、客户画像、案例库、诊断流程 辅助生成方案和交付物。

一人公司：读取商业模式、产品路线、客户反馈、定价体系 推进内容、销售、交付和复盘。

研究者：读取论文笔记、研究问题、引用库和写作计划 辅助综述、假设生成和论文写作。

企业知识系统：扩展为团队上下文系统 组织身份、部门目标、项目进度、知识库、权限制度、审批机制。

15. 从个人到产品：TALOS 的商业化路径 Commercialization

TALOS 的产品化不是卖模板，是卖"AI 时代的认知操作系统"。结合外挂大脑产品化方案，分四层产品：

层级	产品	价值
L0	免费插件 / 开源模板	建立心智，占领关键词
L1	预制 Vault + 教程	让用户照着搭起来
L2	同辈陪跑营	解决卡住、没人反馈的问题
L3	1v1 定制	替客户搭好可运行系统

核心卖点不是「Obsidian 模板」：让 AI 认识你，帮你干活，并持续沉淀你的个人资产。

16. 未来判断 Outlook

每个人都需要一份AI可读的自己：简历让公司理解你，作品集让客户理解你，TALOS让AI理解你。

Context 会成为新型个人资产：个人知识库、审美样本、决策记录、工作流、AI 协作协议。

从软件使用者到系统搭建者：不追工具、不囤提示词，而是搭一套让 AI 替自己干活的系统。

模型会商品化，上下文会差异化：当模型能力趋同，真正区分输出质量的是你的Context、工具环境、审美样本、工作流与判断标准。

17. 结论 Conclusion

TALOS 个人上下文操作系统是智能体时代的个人基础设施。它不是普通知识库，不是单次提示词，不是模型微调，也不是平台记忆功能。它是一套由个人拥有、维护、迁移和授权的上下文资产系统。

把隐性知识显性化。把经验结构化。把审美样本化。把工作流协议化。把权限边界制度化。

未来的 AI 协作差距，不只是模型差距，是上下文差距。谁能更好地结构化自己的经验、审美、目标、项目和工作流，谁就能更好地调用 AI 智能体。这就是 TALOS 的理论基石，也是「系统搭建者」路线的核心基础设施。

18. 参考文献与外部来源 References

科研论文

Packer et al. MemGPT: Towards LLMs as Operating Systems. arXiv:2310.08560

Park et al. Generative Agents: Interactive Simulacra of Human Behavior. arXiv:2304.03442

Mem0 Team. Mem0: Scalable Long-Term Memory for AI Agents. arXiv:2504.19413

Zep: A Temporal Knowledge Graph Architecture for Agent Memory. arXiv:2501.13956

Balog & Kenter. Personal Knowledge Graphs: A Research Agenda. SIGIR 2021

Lewis et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS 2020

产业与产品资料

OpenAI. Memory and new controls for ChatGPT

Anthropic. Introducing the Model Context Protocol

HumanLayer. 12-Factor Agents Letta Docs. Agent memory & architecture

Zep Docs. Agent Memory AWS. Amazon Bedrock AgentCore Memory

库内理论来源

Context资产论 后指令时代 Harness决定Agent天花板 AI上下文经济学 AI落地三原则 外挂大脑产品化方案
TELOS CONTEXT PROFILE